Travaux dirigés n° 2 : Concentration, théorie de VC

Stephan Clémençon <stephan.clemencon@telecom-paris.fr>
Ekhine Irurozki <irurozki@telecom-paris.fr>

Exercice 1. On se place dans le cadre de la classification binaire : soient un descripteur aléatoire X à valeurs dans un espace mesurable $\mathcal{X} \subset \mathbb{R}^d$ ($d \in \mathbb{N}^*$) et un label aléatoire Y valant -1 ou 1. On considère une classe finie $\mathcal{G}$ de classifieurs $\mathcal{X} \to \{-1, 1\}$ telle que les deux labels sont parfaitement séparables par un élément de $\mathcal{G}$, *i.e.* $\min_{g \in \mathcal{G}} \mathrm{L}(g) = 0$ pour le risque $\mathrm{L} : g \in \mathcal{G} \mapsto \mathbb{P}\left(g(\mathrm{X}) \neq \mathrm{Y}\right) \in [0, 1]$.

Soit $n \in \mathbb{N}^*$. On suppose que l'on dispose d'un échantillon i.i.d. $\{(\mathrm{X}_i, \mathrm{Y}_i)\}_{1 \leq i \leq n}$ suivant la même loi que (X, Y) et on note $\hat{g}_n$ un minimiseur de l'erreur empirique de classification :

$$\hat{g}_n \in \min_{g \in \mathcal{G}} \mathrm{L}_n(g) \quad \text{où} \quad \mathrm{L}_n : g \in \mathcal{G} \mapsto \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{g(\mathrm{X}_i) \neq \mathrm{Y}_i\}}.$$

1) Montrer que $\min_{g \in \mathcal{G}} \mathrm{L}_n(g) = 0$ presque-sûrement.
2) Montrer que $\mathbb{P}\left(\mathrm{L}(\hat{g}_n) > \epsilon\right) \leq |\mathcal{G}|(1-\epsilon)^n$ pour tout $\epsilon \in [0, 1]$.
   En déduire que $\mathbb{P}\left(\mathrm{L}(\hat{g}_n) > \epsilon\right) \leq |\mathcal{G}| e^{-n\epsilon}$ pour tout $\epsilon > 0$.

   Indication. Utiliser $\mathcal{G}_{\mathrm{B}} := \{g \in \mathcal{G} : \mathrm{L}(g) > \epsilon\}$ ainsi qu'une borne d'union.
3) Déduire de la question précédente que $\mathbb{E}\left(\mathrm{L}(\hat{g}_n)\right) \leq \dfrac{\log(e|\mathcal{G}|)}{n}$.

   Indication. Pour toute variable aléatoire Z positive, $\mathbb{E}\left(\mathrm{Z}\right) = \int_0^{+\infty} \mathbb{P}(\mathrm{Z} > t)\, dt$.

Exercice 2. On se place dans le cadre de la classification binaire. On utilisera les mêmes notations que dans l'exercice précédent. On pose $\mathrm{L}^* := \mathrm{L}(g^*)$ avec $g^* : x \in \mathcal{X} \mapsto 2\mathbb{1}_{\{\eta(x) \geq 1/2\}} - 1$ et on note $\eta : x \in \mathcal{X} \mapsto \mathbb{P}(\mathrm{Y} = 1 \mid \mathrm{X} = x) \in [0, 1]$ la fonction de régression. Soit $(\eta_n)_{n \in \mathbb{N}^*}$ une suite de fonctions définies sur $\mathcal{X}$ à valeurs dans $]0, 1[$. Pour tout $n \in \mathbb{N}^*$ on considère le classifieur $g_n : x \in \mathcal{X} \mapsto 2\mathbb{1}_{\{\eta_n(x) \geq 1/2\}} - 1$.

1) On suppose qu'il existe $\delta > 0$ tel que $|\eta(x) - 1/2| \geq \delta$ pour tout $x \in \mathcal{X}$. Montrer que

$$\mathrm{L}(g_n) - \mathrm{L}^* \leq \frac{2\,\mathbb{E}\left((\eta_n(\mathrm{X}) - \eta(\mathrm{X}))^2\right)}{\delta}.$$

2) Montrer que si $\mathrm{L}^* = 0$, alors quel que soit $q \in [1, +\infty[$

$$\mathrm{L}(g_n) \leq 2^q\, \mathbb{E}\left(|\eta_n(\mathrm{X}) - \eta(\mathrm{X})|^q\right).$$

Soient maintenant $\eta' : \mathcal{X} \to]0, 1[$ et $g : x \in \mathcal{X} \mapsto 2\mathbb{1}_{\{\eta'(x) \geq 1/2\}} - 1$.

3) On suppose que $\mathbb{P}\{\eta'(\mathrm{X}) = 1/2\} = 0$ et que $\mathbb{E}\left(|\eta_n(\mathrm{X}) - \eta'(\mathrm{X})|\right) \to 0$ lorsque $n \to +\infty$. Montrer que $\mathrm{L}(g_n) \to \mathrm{L}(g)$ lorsque $n \to +\infty$.

4) On suppose que le label Y n'est plus observable, mais qu'une variable Z à valeurs dans $\{-1, +1\}$ l'est, telle que :

$$\begin{aligned} \mathbb{P}\left(\mathrm{Z} = 1 \mid \mathrm{Y} = -1,\ \mathrm{X}\right) &= \mathbb{P}\left(\mathrm{Z} = 1 \mid \mathrm{Y} = -1\right) = a < 1/2, \\ \mathbb{P}\left(\mathrm{Z} = -1 \mid \mathrm{Y} = 1,\ \mathrm{X}\right) &= \mathbb{P}\left(\mathrm{Z} = -1 \mid \mathrm{Y} = 1\right) = b < 1/2. \end{aligned}$$

On pose à présent $\eta' : x \in \mathcal{X} \mapsto \mathbb{P}\left(\mathrm{Z} = +1 \mid \mathrm{X} = x\right)$. Montrer que :

$$\mathrm{L}(g) \leq \mathrm{L}^* \left(1 + \frac{2\,|a-b|}{1 - 2\max(a,b)}\right).$$

Que peut-on en déduire lorsque $a = b$?

Exercice 3. Calculer la VC dimension des classes $\mathcal{A}$ d'ensembles suivantes :

1) $\mathcal{A} = \left\{\ ]-\infty, x_1] \times \ldots \times]-\infty, x_d]\ :\ (x_1, \ldots, x_d) \in \mathbb{R}^d\ \right\}$,
2) $\mathcal{A}$ est constituée des rectangles de $\mathbb{R}^d$.

Exercice 4. Donner une borne supérieure de la VC dimension de la classe des boules fermées dans $\mathbb{R}^d$:

$$\mathcal{A} = \left\{ \left\{ x = (x_1, \ldots, x_d) \in \mathbb{R}^d\ :\ \sum_{i=1}^{d} |x_i - a_i|^2 \leq b \right\} : a_1, \ldots, a_d, b \in \mathbb{R} \right\}.$$

Exercice 5. Soit $\mathcal{A}$ une classe d'ensembles de $\mathbb{R}^d$ de VC dimension $\mathrm{V} < +\infty$ et de coefficients d'éclatement $s(\mathcal{A}, n)$, $\forall n \in \mathbb{N}^*$.

1) Montrer que : $\forall n \geq 1$, $s(\mathcal{A}, n) \leq (n+1)^{\mathrm{V}}$.
2) Montrer que : $\forall n \geq \mathrm{V}$, $s(\mathcal{A}, n) \leq (ne/\mathrm{V})^{\mathrm{V}}$.

Indication. On utilisera le lemme de Sauer : $\forall n \geq 1$, $s(\mathcal{A}, n) \leq \displaystyle\sum_{k=0}^{\mathrm{V}} \binom{n}{k}$.